文本—视觉特权信息自蒸馏：完整正式实验方案 v1.0

0. 项目目标与核心研究问题

本项目建立在 Vision-OPD 的 regional-to-global on-policy self-distillation 思路之上。Vision-OPD 观察到，同一个 MLLM 在得到聚焦关键证据的 crop 后，比面对完整图像时表现更好，因此将 crop 视作训练时的 privileged visual information，并利用学生自身 rollout 上的 token-level distribution matching，将这种"看局部更容易"的能力转移给完整图像条件下的学生。原论文使用约 6.2K 合成样本，在 Qwen3.5-4B/9B 上进行实验。

本研究进一步提出：

> 除视觉模态的特权信息 V 外，是否存在一种文本模态的特权信息 T，能够通过提供位于"图像证据 → 最终答案"推理路径中的引导性中间问题或中间状态，使同一个模型形成更强的 teacher policy，并通过 on-policy self-distillation 将这种优势内化到没有引导信息的普通学生中？

进一步研究：

> 视觉特权和文本推理特权分别改善什么能力？二者是互补、冗余还是相互干扰？这种效应如何随视觉困难度、推理深度和任务结构变化？

最终测试时，所有正式比较模型均只接受：

$$C_S = (I, Q)$$

即：

完整原图 + 最终问题

不提供 crop，不提供 guiding questions，不提供中间答案。

因此所有提升都必须表现为模型自身能力的变化，而不是 inference-time augmentation。

---

1. 术语统一

设：

- I：完整原始图像；
- C：与最终问题相关的证据 crop；
- Q：最终测试问题；
- A^*：最终正确答案；
- G_Q：引导性问题序列；

- G_{QA}：引导问题及其已验证中间答案组成的 reasoning path；
- π_θ：student policy；
- $\pi_{\bar{\theta}}$：EMA teacher policy。

文本特权暂分为两个候选实现。

T-Q：Guiding Questions

教师看到：

$$(I, G_Q, Q)$$

例如：

```
Guide 1: 哪个人与飞机驾驶舱直接相关？
Guide 2: 该人物佩戴的主要通讯设备是什么？

Final Question:
该设备是什么颜色？
```

这里教师仍需自行回答引导问题。

T-QA：Privileged Reasoning Path

教师看到：

$$(I, G_{QA}, Q)$$

例如：

```
Guide 1: 哪个人与飞机驾驶舱直接相关？
Intermediate answer: 飞行员。

Guide 2: 该人物佩戴的主要通讯设备是什么？
Intermediate answer: 头戴式耳机。

Final Question:
该设备是什么颜色？
```

最终答案“耳机颜色”仍然没有被泄露。

T-Q 更贴近当前“引导问题”的原始设想；T-QA 更接近“做第三道物理小问时，前两小问已经完成”的认知类比。

正式方法究竟采用 T-Q 还是 T-QA，不提前凭直觉决定，而由 Stage 0 的 privilege-gap screening 决定。

---

2. 预注册研究假设

H1：Text Privilege Gap

同一个未经训练的模型满足：

$$Perf(I, G, Q) > Perf(I, Q)$$

即文本引导本身构成有效 privileged information。

H2：Text Privilege Transfer

经过文本特权 OPSD 后：

$$Perf(\pi_T; I, Q) > Perf(\pi_{00}; I, Q)$$

即推理时完全删除引导信息，学生仍然得到能力提升。

H3：模态能力分工

视觉特权的收益主要集中于：

- small target；
- low visual clarity；
- fine-grained recognition；
- difficult localization。

文本特权的收益主要集中于：

- multi-hop；
- relational reasoning；
- evidence integration；
- logical bridge；
- 高 reasoning depth。

H4：双模态互补

对于同时具有视觉瓶颈和推理瓶颈的问题：

$$Perf(VT) > \max(Perf(V), Perf(T))$$

如果不成立，则进一步判断二者是信息冗余还是训练干扰。

H5：结构化引导优于“多给文本”

预期：

$$T_{\text{ordered}} > T_{\text{shuffled/random/generic}}$$

如果成立，说明真正发挥作用的是 reasoning structure，而不是额外 context/token 数量。

H6：Text-OPD 收益随 reasoning depth 增加

例如预期出现：

$$Gain_T(D=4) > Gain_T(D=3) > Gain_T(D=2)$$

这是“强化长线推理”假设最直接的验证。

H7：Teacher Gap 与 Distilled Gain 正相关

privileged teacher 相对 student 的优势越大，其可被转移的能力越多。

H8：不得以压缩真实推理搜索为代价

需要验证 Text-OPD 是否只是让模型更快、更确定，却损害长推理中的：

- exploration；
- verification；
- backtracking；
- self-correction。

这一点必须单独检查。近期关于 privileged-context OPSD 的研究发现，它可能改善 instruction-style model，却在较强 thinking model 的长推理轨迹上抑制分叉和自纠错，从而降低长预算准确率。

因此不能仅凭最终短答案 accuracy 宣称“long reasoning capability improved”。

---

3. 整体实验路线

整个项目采用以下顺序：

```
Stage 0
Privilege Gap Screening
        ↓
Stage 1
T-only 小规模训练验证
        ↓
Stage 2
Vision-OPD 严格复现
        ↓
Stage 3
正式数据集构建
        ↓
Stage 4
V × T 2×2 主实验
        ↓
Stage 5
能力分层 / Difficulty / Depth 分析
        ↓
Stage 6
Text Guidance 消融
        ↓
Stage 7
V-T 相互作用与融合策略
        ↓
Stage 8
Thinking-mode 压力测试
        ↓
Stage 9
机制分析、统计检验、外部 benchmark
```

任何阶段发现基础假设不成立，都先修正前一阶段，而不是继续堆模型。

---

4. 两条实验主线必须分开

这是整个设计中非常重要的一点。

Track A：严格 Vision-OPD Reproduction

完全按照原论文数据形式和代码复现。

Vision-OPD 的学生事实上看到的是**带 bounding box 的完整图像以及空间约束**，教师看到裁剪并放大的局部图。因此原方法并不是简单的：

$$I \rightarrow Crop$$

而是构造：

$$x_{\text{global-box}}$$

和：

$$x_{\text{crop}}$$

进行 regional-to-global distillation。

Track A 的唯一目的：

> 证明本项目的训练框架可以正确复现 Vision-OPD。

不得随意修改。

Track B：本研究的 Generalized Privileged Information Framework

主研究使用真正干净的 additive factorial design。

Student：

$$C_S = [I, Q]$$

Teacher-00：

$$C_{00} = [I, Q]$$

Teacher-V：

$$C_V = [I, C, Q]$$

Teacher-T：

$$C_T = [I, G, Q]$$

Teacher-VT：

$$C_{VT} = [I, C, G, Q]$$

即所有 teacher 都保留共同基础信息 I, Q，然后分别“增加”视觉或文本 privilege。

这样：

$$V = 0/1, \quad T = 0/1$$

才构成真正意义上的 2×2 factorial experiment。

否则如果 V teacher 只看 crop，而 T teacher 看 full image，视觉输入内容本身发生替换，会产生额外混杂因素。

---

5. 为什么不能只使用 Vision-OPD 原来的问题

Vision-OPD 的原始数据主要针对：

> small/local evidence → fine-grained question

这非常适合测试视觉定位和局部识别，但很多问题可能本身并不需要长推理。

如果最终问题只是：

> “耳机是什么颜色？”

那么即使人工增加三个前置问题：

> 机场 → 飞机 → 飞行员 → 耳机颜色

也可能只是人为拉长路径，而不是问题本身具有真正的 multi-hop dependency。

因此正式数据必须主动构造三类任务。

---

6. 正式数据集三大任务层

P：Perception-Bottleneck

视觉困难、推理较浅。

例如：

> 某个很小目标的颜色、文字、部件、状态是什么？

典型属性：

- target area 小；
- crop 带来明显优势；
- reasoning depth 1–2；

- 单一区域基本可以解决。

理论预测：

$$V > T$$

R：Reasoning-Bottleneck

视觉证据本身比较清晰，但必须组合多个中间关系。

例如：

> 哪一个人与某物存在特定关系 → 他正在使用什么 → 该行为说明什么？

或者：

> 记分牌 A + 记分牌 B + 队伍对应关系 → 谁领先？

典型属性：

- visual clarity 较高；
- target 不一定小；
- reasoning depth ≥3；
- 多实体或多证据；
- 单个 crop 不足以直接回答。

理论预测：

$$T > V$$

PR：Perception + Reasoning Dual Bottleneck

同时存在：

1. 小区域视觉证据；
2. 多步 reasoning dependency。

例如：

> 先通过人物—车辆关系锁定目标 → 查看该人物手中很小的工具 → 根据工具和接触对象判断其行为。

理论预测：

$$VT > \max(V, T)$$

如果这个预测成立，将成为双模态 PI 最有价值的证据。

---

7. 正式数据规模

推荐正式版本：

Split	数量	用途
Train	8,000	OPSD
Validation	1,000	超参数与早期选择
Internal Diagnostic Test	2,000	主要机制分析
Stage-0 Screening	400–600	privilege gap
Human Audit subset	≥5–10%	数据质量检查

Train 中尽量保证：

$$P : R : PR \approx 1 : 1 : 1$$

不要求绝对相等，但不能让 P 类占绝大多数。

若第一版资源有限，可先使用：

$$6K + 800 + 1.2K$$

正式论文版本再扩展。

---

8. 数据划分必须以 original image 为单位

严禁：

```
Image A / Question 1 → train
Image A / Question 2 → test
```

正确方式：

$$I_i \in Train \Rightarrow \forall Q(I_i) \in Train$$

同时保存：

```
source_image_id
source_dataset
scene_id
```

如能识别近重复图片，再使用 perceptual hash / image embedding 去重。

最终要求：

> Train / Validation / Diagnostic Test 之间不存在相同或近重复场景。

否则模型可能通过场景记忆获得虚假增益。

---

9. 每个正式样本的数据结构

建议从一开始就存储如下字段：

```
sample_id
source_image_id
source_dataset

image_original
image_width
image_height

final_question
option_A
option_B
option_C
option_D
final_answer

task_family:
    P / R / PR

guidance_strategy:
    localization
    entity_tracking
    relation_chain
    attribute_decomposition
    disambiguation
    logical_bridge
    causal_functional
    evidence_integration
```

```
guide_1_question
guide_1_answer
guide_2_question
guide_2_answer
guide_3_question
guide_3_answer
guide_4_question
guide_4_answer

reasoning_depth

evidence_region_1_bbox
evidence_region_2_bbox
...

crop_primary
crop_secondary

target_area_ratio
num_required_regions
num_required_entities

visual_clarity:
    low / medium / high

visual_dependency:
    low / medium / high

guide_dependency_score
guide_relevance_score
guide_answerability_score
answer_leakage_score

teacher_gap_S_T
teacher_gap_S_V
teacher_gap_V_T

human_verified
generation_model
verification_model
data_version
```

这一步非常重要。

后期最有价值的实验往往不是重新训练模型，而是根据这些 metadata 重新切测试集。

---

10. Guidance Strategy 正式分类体系

主数据建议至少包含四种核心策略。

A. Hierarchical Localization

核心：

$$Scene \rightarrow Region \rightarrow Entity \rightarrow Attribute$$

主要解决：

> 去哪里看。

B. Relational / Entity Chain

核心：

$$Entity_A \xrightarrow{relation} Entity_B \xrightarrow{relation} Entity_C \rightarrow Answer$$

主要解决：

> 应该沿着什么实体关系寻找目标。

C. Logical Bridge

核心：

$$Evidence \rightarrow Intermediate\ Conclusion \rightarrow Higher\ Conclusion \rightarrow Answer$$

主要解决：

> 从视觉事实如何推出结论。

D. Evidence Integration

核心：

$$E_1, E_2, E_3 \rightarrow H \rightarrow Answer$$

主要解决：

多个分散证据如何汇聚。

正式第二阶段可加入：

- attribute decomposition；
- disambiguation；
- causal-functional；
- contrastive/counterfactual guidance。

但第一轮主实验中不要让策略种类过多导致每类样本不足。

---

11. Reasoning Depth 的操作性定义

不要按照“问题看起来复杂”人工评分。

定义：

从原始视觉 evidence 到最终答案之间，至少需要多少个不可省略的中间信息转换。

例如：

Depth 1

$$E_1 \rightarrow A$$

Depth 2

$$E_1 \rightarrow H_1 \rightarrow A$$

Depth 3

$$E_1 \rightarrow H_1 \rightarrow H_2 \rightarrow A$$

Depth 4+

至少三层以上有效中间状态。

正式测试尽量保证：

Depth	Diagnostic test
1	≥300
2	≥400

Depth	Diagnostic test
3	≥400
4+	≥400

其余用于其他组合分析。

---

12. “真正的推理链”必须通过 Dependency Test

仅仅生成：

```
Q1
Q2
Q3
Final Q
```

不代表存在真实推理。

定义 guide g_i 的删除贡献：

$$Contribution(g_i) = \log P(A^*|I, G, Q) - \log P(A^*|I, G \setminus g_i, Q)$$

如果：

$$Contribution(g_i) \approx 0$$

则说明该 guide 很可能不是关键 reasoning node。

数据筛选中至少进行：

完整链

$$G_1, G_2, G_3$$

删除 G1

$$G_2, G_3$$

删除 G2

$$G_1, G_3$$

删除 G3

$$G_1, G_2$$

以此检测伪引导。

不要求每一步都是绝对必要，但必须至少达到“有明确增益”。

---

13. Chain Order Test

对于：

$$G_1 \rightarrow G_2 \rightarrow G_3$$

构造：

$$G_3, G_1, G_2$$

保持：

- 文字内容相同；
- token 总量相近；
- 中间答案相同。

仅破坏 reasoning order。

如果：

$$Perf(G_{\text{ordered}}) > Perf(G_{\text{shuffle}})$$

就得到非常重要的证据：

> teacher 利用的是推理结构，而不只是额外事实。

---

14. 数据生成完整 Pipeline

Step 1：视觉结构解析

对原始图像生成：

- objects；
- entities；
- bounding boxes；

- attributes；
- spatial relations；
- interactions；
- candidate evidence regions。

Vision-OPD 原数据也是先利用 object recognition / segmentation 获取候选小区域，再从区域生成 fine-grained questions。

Step 2：先生成 Final Question

原则：

> 先确定模型最终需要解决的问题，再设计 guides。

不能反过来先生成三道小问，再硬凑一个 final question。

Step 3：生成 latent reasoning graph

生成器首先输出：

```
Required evidence:
E1 = ...
E2 = ...

Intermediate state H1:
...

Intermediate state H2:
...

Final inference:
...

Answer:
...
```

例如：

```
E1: 该人物靠近驾驶舱
        ↓
H1: 此人为飞行员
        ↓
```

```
E2: 该人物佩戴头戴式设备
        ↓
H2: 设备为耳机
        ↓
Final:
耳机颜色 = 蓝色
```

Step 4：Graph → Guiding Questions

仅将中间节点转化为自然问题。

最终答案对应节点不得进入 guide answer。

---

15. Guide 生成约束

每个 guide 必须满足：

1. Answerable

能够根据图像或前一节点可靠回答。

2. Path Relevant

属于从视觉 evidence 到 final answer 的有效路径。

3. Non-leaking

不得提前给出最终目标属性。

错误：

> “飞行员戴的是红色耳机吗？”

Final：

> “耳机是什么颜色？”

---

4. Locally Useful

知道该 guide 的答案后，下一步的不确定性应下降。

5. No Trivial Restatement

不能只是重新措辞 final question。

6. No Generic Prompt

例如：

> “请仔细查看图片相关区域。”

这种不属于 privileged reasoning information，只能用于 generic-prompt control。

---

16. 自动数据质检

每条样本至少由独立 verifier 给出：

```
answerability: 0/1/2
logical_dependency: 0/1/2
relevance: 0/1/2
answer_leakage: 0/1
ambiguity: 0/1/2
visual_grounding: 0/1/2
```

其中：

- answerability 必须高；
- relevance 必须高；
- dependency 至少中等；
- leakage 必须为 0；
- final answer 必须唯一。

Vision-OPD 为获得较可靠的合成答案，也使用强模型多次生成并只保留多数答案达到严格一致性的样本。

你们可以沿用类似思想：

> final answer / critical intermediate answer 若多次生成一致率不足，则剔除。

---

17. 人工抽查

正式数据生成完后：

- 随机抽查 5–10%；
- 所有 verifier 边界样本全部人工复查；
- P/R/PR 分层抽样；
- 各 guidance strategy 分层抽样。

人工判断：

1. Final answer 是否正确；
2. Guides 是否真实有效；
3. 是否发生答案泄漏；
4. Reasoning depth 标签是否合理；
5. Crop 是否包含真实关键证据；
6. 是否存在多解。

若有两名标注者，可以报告 Cohen's κ 或一致率。

---

18. 选择题设计

内部 controlled dataset 强烈建议保持 A/B/C/D 选择题形式。

原因是可以避免 LLM judge 带来的噪声，同时获得：

$$P(A), P(B), P(C), P(D)$$

建议：

- A/B/C/D 正确选项近似均匀；
- distractor 必须具有合理视觉/语义可能性；
- 不允许正确选项明显更长；
- 生成后随机打乱 option order。

内部测试同时运行两种 evaluation。

Choice Scoring

直接获取答案位置的 option probability。

Free Generation

模型完整回答，再抽取：

```
[FINAL] C
```

Choice scoring 用于机制分析。

Generation accuracy 用于与实际 inference 行为一致的结果。

---

19. Stage 0：Privilege Gap Screening

样本

推荐：

$$N = 400 \sim 600$$

覆盖：

- P；
- R；
- PR；
- 四大 guidance strategies；
- depth 1–4+。

不训练模型。

---

20. Stage 0 输入条件

同一个 frozen checkpoint 分别运行：

条件	输入
S	I, Q
V-crop	C, Q
V-add	I, C, Q
T-Q	I, G_Q, Q
T-QA	I, G_{QA}, Q
VT	I, C, G_{QA}, Q
T-random	I, G_{random}, Q

条件	输入
T-shuffle	$I, G_{shuffle}, Q$
T-generic	$I, G_{generic}, Q$

其中：

T-random 必须长度匹配。

最好使用同一图像中与最终问题无关的真实 QA，而不是完全胡言乱语。

这样才能排除：

> “只要给模型多一点图像描述就会提高。”

---

21. Stage 0 指标

Accuracy Gap

$$\Delta Acc_T = Acc_T - Acc_S$$

Correct-Answer Log Probability Gap

$$\Delta LP_T = \log P_T(A^*) - \log P_S(A^*)$$

这是非常重要的指标。

因为可能出现：

```
S:
A = .48
B = .44

T:
A = .82
B = .10
```

二者 accuracy 都为 1，但 teacher 显然更可靠。

Margin Improvement

定义：

$$M = P(A^*) - \max_{a \neq A^*} P(a)$$

比较：

$$\Delta M = M_T - M_S$$

Entropy

$$H(p) = -\sum_a p(a) \log p(a)$$

检查 T 是否只是让模型“更确定”，还是“更正确”。

Student-Teacher JSD

$$D_{ST} = JSD(P_S, P_T)$$

---

22. T-Q 与 T-QA 主方法选择规则

计算：

$$G_Q = \Delta LP_{TQ}$$

$$G_{QA} = \Delta LP_{TQA}$$

如果：

1. $G_Q > 0$ 且 paired CI 稳定；
2. T-Q 达到 T-QA 大部分 teacher gain；
3. 最终 accuracy 同样具有稳定改善；

则优先选择 **T-Q** 作为主方法，因为更贴合“引导性问题”原始理论。

如果：

$$T_Q \approx S$$

而：

$$T_{QA} \gg S$$

则主方法改为：

> Privileged Reasoning Path Distillation

也就是 T-QA。

这时论文中不能再把贡献表述为单纯“guiding questions”，而应该明确：

> 有效 PI 是中间 reasoning states。

T-Q 作为消融实验保留。

---

23. Stage 0 的 Go / No-Go

满足以下结果才进入正式 T training：

Go

- T 对 S 存在稳定的 positive teacher gap；
- 正确答案 log-prob 显著增加；
- random/generic 不具有相同效果；
- 至少部分 depth≥3 数据存在清晰提升。

No-Go

如果：

$$T \approx S$$

不要训练。

优先排查：

- guides 太弱；
- questions 只是相关但非依赖；
- final question 太简单；
- QA chain 泄漏/冗余；
- reasoning task 构造失败。

---

24. Stage 1：T-only 小规模预训练验证

推荐：

$$1K \sim 2K$$

训练样本。

使用 Qwen3.5-4B。

第一轮可以单 seed 搜索方向，确认有效后关键比较再使用 3 seeds。

---

25. Stage 1 模型组

至少：

ID	方法
B0	Base checkpoint
B1	Final-answer SFT
B2	Vanilla/00 OPD
B3	Random-T OPD
B4	Real T-Q OPD
B5	Real T-QA OPD

如果 Stage 0 已明确 T-Q 极弱，可以把 B4 降级为 ablation。

---

26. 为什么一定要有 Vanilla OPD

主 factorial 的真正控制组不能只有“完全不训练”。

因为：

$$V/T \text{ model}$$

经历了：

- rollout；
- optimizer update；

- EMA teacher；
- JSD training。

Base 完全没经历这些。

因此正式比较至少应存在：

$$OPD_{00}$$

其中 teacher 和 student 使用相同基础 context：

$$[I, Q]$$

teacher 仍由 EMA 参数产生。

这样能够回答：

> 增益来自 privileged information，还是单纯来自 on-policy self-training？

同时保留 Base，用于测量训练整体影响。

---

27. Off-Policy/SFT 对照

推荐加入：

Final-answer SFT

student：

$$(I, Q) \to A$$

Privileged-response SFT

先让 privileged teacher 产生 response：

$$R_T \sim \pi_T(I, G, Q)$$

然后 student 使用：

$$(I, Q) \to R_T$$

进行普通 SFT。

这样直接比较：

$$\text{Off-policy imitation}$$

和：

$$\text{On-policy dense distribution distillation}$$

究竟哪一种更有效。

---

28. Stage 2：严格复现 Vision-OPD

使用官方代码和数据。

当前公开实现的主要配置包括：

- Qwen3.5-4B；
- EMA teacher；
- teacher update rate 0.05；
- batch size 96；
- rollout $N = 8$；
- learning rate 2×10^{-6}；
- JSD $\beta = 0.5$；
- top-K=100；
- prompt max 8192；
- response max 1024；
- 1 epoch。

原论文的 ablation 表明 JSD 0.5 优于其测试的 forward/reverse KL，且 Top-K=100 的 dense logit distillation 优于 sampled-token objective，因此第一版扩展实验没有必要重新搜索这两个超参数。

首先复现：

$$Base_{4B} \rightarrow VisionOPD_{4B}$$

若资源允许再验证 9B。

只有 reproduction 正常，才能正式解释后面的 V/T 差异。

---

29. 正式 OPSD 数学形式

student 从无特权 context 生成：

$$y \sim \pi_\theta(\cdot|I, Q)$$

对于每个学生生成 token y_t，student：

$$p_S^t = \pi_\theta(\cdot|I, Q, y_{<t})$$

teacher：

$$p_T^t = \pi_{\bar{\theta}}(\cdot|C_T, y_{<t})$$

其中 C_T 为 V、T 或 VT context。

损失：

$$\mathcal{L} = \frac{1}{|y|}\sum_t JSD(p_S^t, p_T^t)$$

teacher stop-gradient。

关键原则是：

> Teacher 不重新生成自己的整条答案。

teacher 与 student 都在：

$$y_{<t}^{student}$$

这个完全相同的 student-generated prefix 上比较 next-token distribution。

这正是 Vision-OPD 的核心 on-policy design。

---

30. EMA Teacher

设 student 更新为：

$$\theta_t$$

teacher：

$$\bar{\theta}_t = (1-\alpha)\bar{\theta}_{t-1} + \alpha\theta_t$$

默认沿用：

$$\alpha = 0.05$$

Vision-OPD 的消融显示没有 teacher regularization 时可能出现严重训练 collapse，因此这一项不应删除。

---

31. Stage 3：正式 2×2 主实验

定义四种 OPSD training regime。

模型	V	T	Teacher Context
M_{00}	0	0	I, Q
M_V	1	0	I, C, Q
M_T	0	1	I, G, Q
M_{VT}	1	1	I, C, G, Q

四个模型的 student rollout 全部来自：

$$(I, Q)$$

四者：

- 初始化 checkpoint 相同；
- train samples 相同；
- data order 相同；
- batch size 相同；
- optimizer 相同；
- rollout 配置相同；
- epoch 相同；
- teacher EMA 相同。

唯一主要变量：

$$V, \quad T$$

---

32. Main 2×2 必须使用多个 seed

正式结论至少：

$$seed_1, seed_2, seed_3$$

分别训练：

$$M_{00}, M_V, M_T, M_{VT}$$

开发阶段：

4B 用于快速迭代和所有消融。

论文主要结果：

9B 进行核心 2×2 的 3-seed 验证。

如果算力充足：

4B 和 9B 主 2×2 都报告 3 seeds。

---

33. 推荐训练分工

4B

负责：

- Stage 0；
- pilot；
- 全部 guidance ablation；
- strategy experiment；
- fusion experiment；
- hyperparameter sanity checks。

9B

负责：

- Base；
- M_{00}；
- M_V；
- M_T；
- M_{VT}；
- 最重要的 1–2 个 ablation。

不要在 9B 上先做大量探索。

---

34. 正式主结果指标

主表：

Model	All	P	R	PR
Base				
OPD-00				
V				
T				
VT				

报告：

$$mean \pm std$$

并给：

$$95\% CI$$

---

35. 模态效应正式定义

视觉主效应：

$$Effect_V = \frac{Perf(M_V) + Perf(M_{VT}) - Perf(M_{00}) - Perf(M_T)}{2}$$

文本主效应：

$$Effect_T = \frac{Perf(M_T) + Perf(M_{VT}) - Perf(M_{00}) - Perf(M_V)}{2}$$

交互效应：

$$Interaction = Perf(M_{VT}) - Perf(M_V) - Perf(M_T) + Perf(M_{00})$$

解释：

$$Interaction > 0$$

V/T 协同。

$$Interaction \approx 0$$

近似独立。

$$Interaction < 0$$

出现冗余或干扰。

这比简单比较：

> “VT 比 T 高多少”

更加严格。

---

36. Teacher Privilege Gap

在训练前，对同一 checkpoint 测：

$$Gap_V = Perf(C_V) - Perf(C_{00})$$

$$Gap_T = Perf(C_T) - Perf(C_{00})$$

$$Gap_{VT} = Perf(C_{VT}) - Perf(C_{00})$$

同时保存 accuracy gap 和 log-prob gap。

---

37. Gap Closure Ratio

训练后定义：

$$Gain_T = Perf(M_T; I, Q) - Perf(M_{00}; I, Q)$$

然后：

$$GCR_T = \frac{Gain_T}{Gap_T}$$

V 和 VT 同理。

例如：

```
普通输入       60
T teacher     75
T-distilled   69
```

则：

$$GCR_T = \frac{69 - 60}{75 - 60} = 60\%$$

即约 60% 的 privileged advantage 被学生内化。

注意：

- GCR 可能 >100%；
- 可能为负；
- 因此它是描述性机制指标，而不是受限比例。

---

38. 最重要的能力分层表

正式论文中建议出现：

Task	Base	00	V	T	VT
Small target					
Large target					
Low clarity					
High clarity					
Localization					
Relation					
Logical bridge					
Evidence integration					
Depth 1					
Depth 2					
Depth 3					
Depth 4+					

真正重要的结论可能不是：

> T 平均 +3.2。

而是：

> T 在 Depth 1 几乎无变化，但在 Depth 4+ 提升明显。

这种结果才真正支持“long-line reasoning enhancement”。

---

39. Depth Scaling 分析

计算：

$$Gain_T(D) = Acc_T(D) - Acc_{00}(D)$$

画：

```
Gain
 ^
 |               *
 |          *
 |      *
 | *
 +--------------------> reasoning depth
    1   2   3   4+
```

统计模型可使用：

$$Correct \sim T + Depth + T \times Depth$$

核心观察：

$$\beta_{T \times Depth}$$

若显著为正，则意味着：

> Text PI 的收益随 reasoning depth 上升。

---

40. Strategy Ablation

正式主数据先使用 mixed strategies：

```
25% Localization
25% Relation
25% Logical Bridge
25% Evidence Integration
```

先训练一个 M_T^{mixed}。

根据标签分别测试四类数据。

如果差异明显，再单独训练：

$$T_{loc}$$

$$T_{rel}$$

$$T_{logic}$$

$$T_{evidence}$$

不要一开始就训练四个独立 strategy 模型。

---

41. Text Privilege 必做消融

至少包含：

Variant	含义
T-Q	只有 guiding questions
T-QA	Q + intermediate answers
Random-T	无关、长度匹配 QA
Shuffled-T	内容相同，顺序破坏
Generic-T	普通“请仔细观察/逐步分析”提示
Partial-T	只给部分链
Full-T	完整链

这组实验回答：

> 是“文本”有效，还是“推理路径”有效？

---

42. Generic Prompt Control

Generic-T 可以使用：

```
请仔细分析图像。
首先确定与问题相关的区域和对象，
```

然后逐步进行推理，
最后回答问题。

如果：

$$T_{structured} > T_{generic}$$

说明收益不能由一般 prompting effect 解释。

---

43. Random-T Control

从同一图片产生长度匹配但与 final answer 无关的 QA：

图中有几栋建筑？
天空中是否有云？

但最终问题可能仍是：

> 飞行员耳机颜色是什么？

比从完全另一张图片随机抽问题更严格，因为它控制了：

> “teacher 获得了更多关于当前图片的信息”

这个因素。

---

44. Visual Sham Control

V 模态也应该做同等级别的 control。

选择：

> 同一图片中面积与真实 crop 相近、但不包含关键 evidence 的区域。

Teacher：

$$[I, C_{sham}, Q]$$

比较：

$$V_{real} \quad vs \quad V_{sham}$$

能够证明真正有效的是 privileged evidence，而不只是“多输入了一张放大图”。

---

45. Partial Chain Experiment

如果完整链：

$$G_1 \rightarrow G_2 \rightarrow G_3$$

训练：

- 1-hop；
- 2-hop；
- 3-hop；
- complete chain。

观察：

$$Gain(k)$$

是否随 chain depth 改变。

这能直接研究：

> privileged information 的量与结构怎样影响可蒸馏性。

---

46. Depth Extrapolation

一个很有论文价值的实验是：

Train：

$$Depth = 2, 3$$

Test：

$$Depth = 4+$$

如果 T-distillation 仍有提升，则更支持：

> 模型学会某种 transferable reasoning mechanism

而不是：

记住训练数据里的固定链模板。

类似地，HopChain 的研究表明完整 multi-hop 训练相比 single-hop/half-chain 数据具有明显更好的跨任务泛化，这支持将“真正的依赖链”作为正式变量，而不是人为增加冗余步骤。

---

47. Strategy Hold-Out Generalization

进一步可以：

Train：

- Localization；
- Relation；
- Logical Bridge。

完全不训练：

- Evidence Integration。

然后测试 Evidence Integration。

反向轮换。

如果仍有 transfer：

T-OPD 学到的可能不是固定引导模板，而是更一般的路径组织能力。

这是研究增强项，不属于第一轮必须实验。

---

48. V/T 融合方式实验

只有先证明：

$$V > 00$$

且：

$$T > 00$$

才进入这一部分。

Fusion A：Simultaneous Teacher

每个 step：

$$Teacher = [I, C, G, Q]$$

损失：

$$L_{VT}$$

Fusion B：Alternating Teacher

训练 step 交替：

```
step 1 → V teacher
step 2 → T teacher
step 3 → V teacher
step 4 → T teacher
```

student 始终：

$$[I, Q]$$

Fusion C：Dual Teacher Loss

同一条 student rollout：

$$L = \lambda L_V + (1 - \lambda) L_T$$

第一轮只测试：

$$\lambda = 0.25, 0.5, 0.75$$

如果 $\lambda = .5$ 已明显优秀，再细搜。

---

49. Teacher Disagreement

对于每个 token：

$$D_{VT}^{(t)} = JSD(P_V^t, P_T^t)$$

样本级：

$$Disagreement = \frac{1}{|y|}\sum_{t} D_{VT}^{(t)}$$

将数据按 disagreement 分成：

- low；
- medium；
- high。

观察：

$$Gain_{VT}$$

是否随 disagreement 下降。

如果出现：

> VT 的负交互主要发生于 V/T teacher 高冲突样本，

则可以非常具体地解释所谓“模态干扰”。

---

50. 为什么 V/T 可能冲突

假设一个问题必须结合全局背景。

V teacher 受到 crop 影响后可能认为：

$$Token = A$$

T teacher 根据全局 relation chain 更倾向：

$$Token = B$$

这时简单 simultaneous teacher 可能并不是最佳策略。

因此：

$$JSD(P_V, P_T)$$

不仅是分析指标，也可以发展为后续 adaptive weighting。

例如未来可研究：

$$\lambda = f(D_{VT})$$

但第一篇工作不必立即实现。

---

51. Thinking Mode 必须独立测试

Vision-OPD 官方 evaluation 对 Qwen3.5 baseline 明确提供 non-thinking 模式设置；其方法首先针对 fine-grained perception，而不是长 deliberative reasoning。

你们的 claim 却包含：

> “强化长线推理能力”。

因此正式实验必须设置两层。

---

52. Layer A：Non-Thinking Main Experiment

主 2×2 首先使用 non-thinking / instruction-style inference。

原因：

- 与 Vision-OPD 最接近；
- rollout 长度可控；
- 不容易把 test-time search 与 PI distillation 混在一起；
- 更适合判断文本 PI 本身是否能 transfer。

这一部分用于证明：

> 方法成立。

---

53. Layer B：Thinking-Mode Stress Test

同一训练后 checkpoint，开启 thinking evaluation。

至少选取：

- R；
- PR；
- Depth 3；
- Depth 4+。

测试多个 inference budget。

例如：

$$512,\ 1024,\ 2048,\ 4096$$

如模型和资源允许，再增加更长 budget。

观察：

$$Accuracy(budget)$$

而不仅看一个固定长度。

---

54. 真正的 long-reasoning 改进应该表现为

理想：

```
                Longer Budget
Base        ──────┐
T-model     ──────────────┐
                          ↑
              优势保持/扩大
```

危险结果：

```
Short budget:
T > Base

Long budget:
T < Base
```

这种情况下不能宣称：

> 长推理能力增强。

更可能说明：

> 模型被训练得更快、更确定，但削弱了搜索和自纠错。

---

55. Thinking Behavior Diagnostics

记录：

Response length

$$L$$

Reconsideration markers

例如：

```
wait
however
but
let me reconsider
another possibility
```

中文对应：

```
等等
但是
重新考虑
另一种可能
检查一下
```

不能只靠词频作为结论，但可作为辅助行为指标。

Token Entropy

关注高 entropy token。

Correction Success

模型出现自我修正后，最终是否从错误路径转向正确答案。

Accuracy × Length Curve

比较不同 inference budget 的收益。

近期研究将 privileged-context OPSD 的一个失败模式归因于高 entropy “forking positions”上的 supervision 改变，因此这一分析对你们尤其重要。

---

56. 外部 Benchmark：视觉能力

必须至少复现 Vision-OPD 的主要 fine-grained benchmark：

- V* Bench；
- ZoomBench；
- HR-Bench 4K；
- HR-Bench 8K；
- MME-RealWorld EN；
- MME-RealWorld CN。

这些也是 Vision-OPD 的核心 evaluation set。

目的：

> 判断 T 是否影响 fine-grained perception，以及 VT 是否保留 V 的提升。

---

57. 外部 Benchmark：一般能力保持

从官方 evaluation pipeline 已支持的 benchmark 中选择：

- MMStar；
- CV-Bench；
- MMVP；
- POPE；
- VisualProbe。

官方 repo 当前已经提供这些 benchmark 的 evaluation 支持。

这里重点不是获得 SOTA，而是检测：

$$\Delta GeneralCapability$$

是否出现明显负迁移。

---

58. 外部长推理 Benchmark

这一部分需要谨慎解释。

M^3-VQA 专门针对 multi-entity / multi-hop multimodal reasoning，但包含知识库、文本材料和 retrieval 等设定；VistaHop 则针对 visual deep search 和多跳视觉证据链，并允许更强的工具式视觉搜索，因此两者与普通 single-image VQA 并不完全同分布。

因此：

> 可以作为 secondary transfer benchmark，不能取代内部 controlled diagnostic set。

最核心的 reasoning 结论必须来自你们自己严格控制：

- Depth；
- Strategy；
- Evidence；
- Target size；
- V/T dependency

的 diagnostic data。

---

59. 内部 Diagnostic Set 才是整个研究最重要的测试集

外部 benchmark 告诉你：

> “有没有泛化。”

内部 diagnostic 告诉你：

> “为什么提高。”

因此内部 2K test 必须永久冻结。

一旦主实验启动：

> 不得继续根据 test 表现修改 data generation。

所有修改只根据 Validation Set。

---

60. 训练期间记录的数据

每个 checkpoint 至少保存：

```
train_step
train_loss
student_teacher_jsd
student_entropy
teacher_entropy
```

```
response_length

sample_id
teacher_type
student_correct
teacher_correct

logp_correct_student
logp_correct_teacher

D_ST
D_SV
D_SText
D_VT
```

随机保存一小部分完整 token-level logit trace，用于机制分析。

---

61. 关键训练曲线

建议画：

Figure A

$$Teacher\text{-}Student\ JSD \quad vs \quad training\ step$$

Figure B

$$Privilege\ Gap \quad vs \quad training\ step$$

Figure C

$$Diagnostic\ Accuracy \quad vs \quad training\ step$$

Figure D

V/T/VT 的 gap closure。

Vision-OPD 本身也通过跟踪 regional-to-global gap 随训练缩小来说明模型正在内化 crop advantage。

你们应该构造对应的：

> Reasoning-Privilege Gap Curve。

---

62. Reasoning-Privilege Gap Curve

训练 checkpoint k：

$$RPG(k) = Perf(\pi_k; I, G, Q) - Perf(\pi_k; I, Q)$$

理想情况：

训练初始：

$$RPG(0) \gg 0$$

训练结束：

$$RPG(K) \downarrow$$

同时：

$$Perf(\pi_K; I, Q) \uparrow$$

即：

> 无特权 student 正逐渐追上 privileged teacher。

这是和 Vision-OPD regional-to-global gap 最直接的理论对应。

---

63. 但是 Gap 下降不能单独证明成功

还可能出现：

$$Teacher \downarrow$$

导致：

$$Gap \downarrow$$

所以必须同时画：

```
Student performance ↑ ?
Teacher performance → / ↑ ?
Gap ↓ ?
```

真正成功应该是：

$$Student \uparrow, \quad Gap \downarrow$$

而不是 teacher degradation。

---

64. 统计检验

内部测试为 paired design，因为每个模型回答完全相同的问题。

主结果推荐：

Clustered paired bootstrap

以：

$$source_image_id$$

作为 bootstrap cluster。

而不是单独抽 question。

原因：

> 同一 image 派生的多个问题并不独立。

报告：

$$95\% CI$$

---

65. Accuracy Pairwise Test

可以使用 McNemar test 比较：

$$M_T \quad vs \quad M_{00}$$

以及：

$$M_{VT} \quad vs \quad M_V$$

等。

大量 subgroup comparison 使用 Holm correction 控制多重比较。

---

66. Factorial Regression

正式分析：

$$Correct \sim V + T + V : T$$

进一步：

$$Correct \sim V + T + V : T + Depth + Clarity + TargetSize$$

研究：

$$T : Depth$$

以及：

$$V : TargetSize$$

如果有多个问题来自同一个 image，可以加入 image-level random effect 或 cluster-robust standard error。

---

67. 不要只报告 p-value

同时报告：

- absolute accuracy difference；
- 95% CI；
- mean ± std across seeds；
- interaction effect；
- subgroup effect；
- log-prob effect。

最核心的东西仍然是：

> 效果大小和可解释性。

---

68. 防止选择偏差

以下内容应在主实验前固定：

- Main dataset version；
- primary metric；
- Base checkpoint；

- seeds；
- main hyperparameters；
- primary benchmark；
- P/R/PR definition；
- guidance strategy definition；
- statistical test。

避免看到结果后再决定：

> “Depth 3 才算长推理。”

---

69. 重要的回答泄漏检查

Text PI 最大风险之一是：

> 中间答案事实上偷偷告诉了最终答案。

需要自动检查：

Lexical leakage

最终 answer 是否直接出现在 guide answer 中。

Semantic leakage

即使没有相同词，中间答案是否唯一编码 final answer。

例如：

```
Final:
耳机是红还是蓝？

Guide:
它不是蓝色。
```

这也是答案泄漏。

这类样本必须删除。

---

70. “学生成功时不再教学”问题

Vision-OPD 官方实现包含对 student self-success 的处理开关。第一轮 T 扩展建议严格沿用官方行为，不自行更改，以免增加变量。

后续可以专门研究：

> 是否只在 teacher 明显优于 student 时才进行 distillation。

例如：

$$w_i = 1[P_T(A^*) > P_S(A^*) + \delta]$$

但这属于后续 adaptive teacher filtering，而非第一版主方法。

---

71. Teacher Advantage Filtering

研究增强项：

把训练样本按照 teacher gap 分层：

Negative teacher

$$\Delta LP < 0$$

Weak teacher

$$0 < \Delta LP < \tau_1$$

Strong teacher

$$\Delta LP > \tau_1$$

研究：

> 是否仅使用 strong-teacher samples 能提高 distillation efficiency。

如果成立，意味着：

> PI 并不是越多越好；只有 teacher 真正因为 PI 获得优势时才值得蒸馏。

---

72. 一个特别重要的机制图

横轴：

$$Pretraining\ Teacher\ Gap$$

纵轴：

$$Posttraining\ Student\ Gain$$

每一个点是一类题或一个 sample bin。

拟合：

$$Gain = \beta_0 + \beta_1 Gap$$

如果：

$$\beta_1 > 0$$

则支持：

> privilege gap 是能力转移的来源。

---

73. 负迁移检查

必须确保：

$$TargetGain > 0$$

同时没有：

$$GeneralCapability \downarrow$$

重点检查：

- hallucination；
- OCR；
- general VQA；
- spatial reasoning；
- normal perception；
- reasoning benchmark。

若 T 在自己的 diagnostic 上提升，但通用视觉全面下降：

这更像 specialization，而不是能力提升。

---

74. 结果解释矩阵

情况 A

$$T_{teacher} > S$$

且：

$$M_T > M_{00}$$

结论：

文本 PI 可以被 self-distilled。

情况 B

$$T_{teacher} > S$$

但：

$$M_T \approx M_{00}$$

说明：

Privilege 存在，但当前 OPSD 未能有效转移。

此时优先研究：

- teacher regularization；
- loss；
- rollout length；
- guide format；
- teacher-student distribution mismatch。

情况 C

$$T_{teacher} \approx S$$

且：

$$M_T \approx M_{00}$$

说明：

主要问题在数据/引导策略，而不是蒸馏。

情况 D

$$T_{teacher} > S$$

但：

$$M_T < M_{00}$$

这是最值得警惕的情况。

可能是：

privileged teacher 给学生提供了错误的 token-level learning signal。

尤其需要检查 thinking fork suppression。

---

75. V/T 结果解释矩阵

V ↑，T ↑，VT ↑↑

最理想：

两种 PI 互补。

V ↑，T ↑，VT ≈ max(V,T)

信息冗余。

V ↑，T ↑，VT ↓

发生 interference。

V ↑，T ≈ 00

文本引导构造失败或任务仍以视觉定位为主。

T ↑，V ≈ 00

正式数据可能主要是 reasoning bottleneck，而非 fine-grained perception。

P 中 V 强、R 中 T 强、PR 中 VT 强

这是理论上最漂亮、最有解释力的结果。

---

76. 判断“文本真的增强了长线推理”的最低证据标准

不能只满足：

$$OverallAcc_T > OverallAcc_{00}$$

至少还应该同时看到：

1. Depth≥3/4 的收益高于 Depth 1；
2. Logical / Evidence Integration 类收益明显；
3. Ordered chain > Random / Generic；
4. Shuffled chain 弱于 Ordered；
5. 删除关键 guide 会降低 teacher advantage；
6. external reasoning benchmark 不发生明显负迁移；
7. thinking-mode 长预算下收益没有反转；
8. self-correction / exploration 没有显著被压制。

达到这些条件，才适合写：

> “Textual privileged reasoning improves long-horizon reasoning.”

否则更安全的表述是：

> “Textual PI improves multimodal task performance.”

---

77. 实验运行优先级

Tier 1：必须完成

- Stage 0 privilege screening；
- T-only pilot；
- Vision-OPD reproduction；
- Main 2×2；
- P/R/PR 分层；

- depth 分层；
- Random-T；
- Shuffled-T；
- Generic-T；
- general capability evaluation。

Tier 2：强烈建议

- T-Q vs T-QA；
- Partial chain；
- V sham；
- teacher disagreement；
- gap closure；
- thinking-mode stress；
- multiple seeds。

Tier 3：论文增强

- Strategy-specific training；
- depth extrapolation；
- strategy hold-out；
- alternating VT；
- dual-teacher loss；
- adaptive weighting；
- teacher-advantage filtering。

---

78. 推荐实际运行顺序

不要一次提交几十个训练任务。

严格按照：

```
① 400–600 samples
   Stage-0 inference

       ↓

② 确认 T-Q / T-QA 哪个形成 teacher gap

       ↓
```

```
③ 1K–2K T-only 4B pilot
       ↓
④ Vision-OPD 官方 4B reproduction
       ↓
⑤ Freeze 正式数据 pipeline
       ↓
⑥ 8K train / 1K val / 2K diagnostic
       ↓
⑦ 4B Main 2×2
       ↓
⑧ 4B 必要 ablations
       ↓
⑨ 9B Main 2×2 × 3 seeds
       ↓
⑩ external benchmark + thinking stress
       ↓
⑪ V/T interaction experiment
       ↓
⑫ final mechanism analysis
```

任何一级失败，先查上一级。

---

79. 实验命名规范

建议统一：

```
BASE-Qwen35-4B

OPD00-Qwen35-4B
OPDV-Qwen35-4B
OPDTQ-Qwen35-4B
OPDTQA-Qwen35-4B
OPDVT-Qwen35-4B

ABL-T-RANDOM
ABL-T-SHUFFLE
ABL-T-GENERIC
ABL-T-PARTIAL

ABL-V-SHAM

FUSION-VT-SIM
FUSION-VT-ALT
FUSION-VT-DUAL050
```

每次 run 记录：

```
git_commit
dataset_version
dataset_hash
model_checkpoint
seed
config
CUDA/environment
training_start_checkpoint
evaluation_config
```

---

80. 数据版本管理

例如：

```
PI-VQA-v0.1
→ generator test

PI-VQA-v0.2
→ Stage 0

PI-VQA-v0.3
```

```
→ Pilot

PI-VQA-v1.0
→ Formal frozen dataset
```

v1.0 一旦进入 main experiment：

> Diagnostic test 不再修改。

后续修复形成：

```
v1.1
```

并明确记录差异。

---

81. 正式论文主表建议

Table 1：Privilege Gap

Context	Acc	Correct LP	Margin
S			
V			
T-Q			
T-QA			
VT			

Table 2：Main 2×2

Model	Overall	P	R	PR
Base				
OPD00				
V				
T				
VT				

Table 3：Reasoning Depth

Model	D1	D2	D3	D4+
00				
V				
T				
VT				

Table 4：Guidance Ablation

Teacher PI	Acc
Ordered QA	
Q only	
Partial	
Shuffle	
Random	
Generic	

Table 5：Generalization

Model	V*	Zoom	HR	MME-RW	General VQA	Reasoning

Table 6：Thinking Stress Test

Model	512	1K	2K	4K	Self-correction

82. 正式论文主图建议

Figure 1

整个：

$$S/V/T/VT$$

框架示意图。

Figure 2

Privilege Gap → Distillation → Gap Closure。

Figure 3

Gain vs Reasoning Depth。

Figure 4

P/R/PR 三种任务上的 V/T/VT specialization。

Figure 5

V-T Teacher Disagreement vs VT Gain。

Figure 6

Thinking-mode Accuracy vs Inference Budget。

---

83. 项目真正最重要的实验不是 VT，而是 T

研究顺序必须始终坚持：

$$S \rightarrow T_{teacher} \rightarrow T_{student}$$

首先回答：

> T 本身是否构成有效 privilege？

然后：

> privilege 能否 transfer？

只有两者都成立，才有资格讨论：

$$V \times T$$

否则 VT 的任何变化都很难解释。

---

84. 最终方法可能出现两个不同版本

情况一：T-Q 已经有效

那么项目主题可以保持：

> Guiding-Question Privileged Self-Distillation

核心直觉非常漂亮：

> 在训练时给 teacher 一组逻辑上位于目标推理路径中的“前置小问”，使 teacher 更容易获得正确思路，再将这种优势蒸馏回直接面对最终问题的 student。

情况二：只有 T-QA 有效

那么不要强行保持“guiding questions”命名。

应该升级成：

> Privileged Reasoning-Path Self-Distillation

其核心是：

$$Input \rightarrow Intermediate\ States \rightarrow Answer$$

这些中间状态只在 training-time teacher 可见。

学生最终学会：

$$Input \rightarrow Answer$$

而不需要 inference-time reasoning scaffold。

这反而可能成为更一般、更有理论价值的方法。

---

85. 如果最终发现 VT 存在干扰，也不是实验失败

例如：

$$V > 00, \quad T > 00$$

但：

$$VT < \max(V, T)$$

这可以进一步形成非常有价值的结论：

> Privileged information 并非简单叠加越多越好。

可能存在：

$$Modality\ Conflict$$

进一步发现：

$$High\ JSD(P_V, P_T) \Rightarrow Low\ VT\ Gain$$

则甚至可能成为论文最重要的分析之一。

---

86. 如果 Thinking Mode 出现退化，同样不应隐藏

假设：

Non-thinking：

$$T > 00$$

Thinking-long-budget：

$$T < 00$$

那么正确结论是：

> Text privileged distillation 可以增强直接推理/短路径能力，却可能压缩模型原有的 test-time reasoning search。

这实际上与近期关于 privileged-context OPSD 的负面结果形成非常重要的多模态对应。

反过来，如果你们能够证明：

$$T > 00$$

并且：

$$LongBudget_T > LongBudget_{00}$$

同时没有 fork/self-correction suppression，

那将成为非常强的新结果。

---

87. 完整实验的核心证据链

最终论文应该让读者依次相信：

Evidence 1

同一个模型在文本推理 privilege 下表现更好：

$$T > S$$

Evidence 2

这种优势不是多几个 token：

$$T_{structured} > T_{random/generic}$$

Evidence 3

这种优势依赖 reasoning structure：

$$T_{ordered} > T_{shuffle}$$

Evidence 4

这种优势可以被蒸馏：

$$M_T > M_{00}$$

Evidence 5

推理时不再需要 T：

$$M_T(I, Q) > M_{00}(I, Q)$$

Evidence 6

效果集中在复杂 reasoning task：

$$Gain_T(D \uparrow) \uparrow$$

Evidence 7

V/T 形成不同 specialization：

$$V \rightarrow Perception$$

$$T \rightarrow Reasoning$$

Evidence 8

PR 任务上 VT 表现出互补，或通过 disagreement 分析解释为何没有互补。

Evidence 9

外部 benchmark 表明能力不是 dataset-specific。

Evidence 10

Thinking-mode stress test 排除"通过压缩搜索换准确率"的替代解释。

完成这十层证据后，整体论证会相当完整。

---

88. 最终可形成的研究主张

如果预期实验结果得到支持，论文的核心贡献可以从最弱到最强表述为：

Level 1

Text-guided privileged information can improve self-distillation for multimodal QA.

Level 2

Structured privileged reasoning paths can be distilled into an unprivileged multimodal policy.

Level 3

Visual and textual privileged information transfer distinct capabilities: visual PI primarily improves fine-grained perception, whereas textual reasoning PI primarily improves multi-hop reasoning.

Level 4

The effectiveness and interaction of privileged information are task-dependent and can be predicted by visual difficulty, reasoning depth, and cross-teacher disagreement.

最终最有价值的理论概括可以是：

> **Privileged information distillation 不只是一种"把答案教给学生"的技术，而是一种利用同一模型在不同信息条件下的能力差，把训练时可获得的"更容易的推理路径"转换为推理时无需额外信息的模型能力的方法。**

Vision-OPD 展示的是：

$$Privileged\ Visual\ View \rightarrow Ordinary\ Visual\ Inference$$

本研究希望验证和扩展为：

$$Privileged\ Reasoning\ Path \rightarrow Direct\ Multimodal\ Inference$$

进一步得到：

$$Visual\ PI + Textual\ PI \rightarrow Generalized\ Privileged\ Information\ Self\text{-}Distillation$$

这应该作为整个正式实验的统一理论主线。